

Adult Census Income 분석 프로젝트 보고서

작성일 : 2026-07-21

광주 1반 1조 : 김지호, 김상훈, 김하연, 박도현, 이슬

github : <https://github.com/simonjiho/data-project>

목차

1. 프로젝트 개요
2. 데이터 준비 및 EDA
3. 시각화 및 검증
4. ML Pipeline 평가
5. 분석결과 및 결론
6. 팀원 별 인사이드 및 의견

1. 프로젝트 개요

1.1 프로젝트 목적

- UCI Adult Census Income 데이터를 활용하여 개인의 인구통계·교육·근로 특성을 분석함.
- 개인의 연간 소득이 50,000달러를 초과하는지 예측하는 이진 분류 모델을 구축함.
- 데이터 로딩부터 전처리, EDA, 통계 검증, 머신러닝 모델링, 결과 보고서 생성까지 하나의 End-to-End 분석 흐름으로 구현함.
- 동일한 입력 데이터와 설정으로 분석 결과를 다시 생성할 수 있는 재현 가능한 파이프라인 구축을 목표로 함.

1.2 주요 분석 사항

1. 소득 그룹별 나이·교육 수준·주당 근무시간에 차이가 존재하는지 확인함.
2. 수치형 변수 사이에 어떠한 선형 관계가 존재하는지 확인함.
3. `>50K` 그룹과 `<=50K` 그룹의 주당 근무시간 분포 및 평균이 다른지 검증함.
4. 교육 수준과 소득 그룹 사이에 통계적 연관성이 존재하는지 검증함.
5. Logistic Regression, Random Forest, HistGradientBoosting 중 소득 구간을 가장 잘 분류하는 모델을 확인함.
6. 클래스 불균형을 고려했을 때 Accuracy 이외의 평가 지표가 어떻게 나타나는지 비교함.

1.3 데이터 출처

- 데이터셋명: Adult Census Income
- 사용 파일: `adult.data`
- 제공 기관: UCI Machine Learning Repository
- 원본 데이터 주소: [UCI Adult 데이터](#)
- 원본 데이터 경로: `data/adult.data`
- 분석 결과 경로: `day2종합실습/output/`

모델 평가용 데이터는 `adult.data` 내부를 학습용 80%, 평가용 20%로 분리하여 구성함.

1.4 데이터 배경

- Barry Becker가 1994년 미국 Census 데이터베이스에서 추출한 자료임.
- 모든 미국 성인을 포함한 전체 모집단 자료가 아니라, 일정 조건을 만족하는 기록만 선별한 표본 데이터임.

원본 데이터 추출 조건은 다음과 같음.

```
나이 > 16
총소득 관련 값 > 100
표본 가중치 > 1
주당 근무시간 > 0
```

따라서 분석 결과를 미국 전체 성인에게 그대로 일반화하는 데 한계가 있음.

1.5 원본 데이터 특징

항목	값
행 수	32,561
열 수	15
입력 변수	14개
목표 변수	income 1개
완전히 같은 추가 중복 행	24개
파일 헤더	없음
값 구분 방식	쉼표 구분
결측값 표시	?

1.6 변수 구성

변수	유형	의미	분석 시 고려사항
age	수치형	나이	소득과 비선형 관계가 존재할 수 있음
workclass	범주형	민간·정부·자영업 등 고용 형태	결측값 존재
fnlwgt	수치형	최종 표본 가중치	개인 특성이 아니므로 ML 입력에서 제외함
education	범주형	문자형 교육 수준	education_num 과 정보가 중복될 수 있음
education_num	수치형	교육 수준 숫자 코드	실제 교육 연수로 단정하기 어려움
marital_status	범주형	혼인 상태	relationship 과 관련성이 높을 수 있음
occupation	범주형	직업 분야	결측값 존재
relationship	범주형	가구 내 관계	혼인 상태와 동일한 변수는 아님
race	범주형	원본 조사상의 인종 범주	민감 변수임
sex	범주형	원본 조사상의 성별	민감 변수임
capital_gain	수치형	자본 이득	대부분 0이고 일부 값이 매우 큼
capital_loss	수치형	자본 손실	대부분 0이고 일부 값이 매우 큼
hours_per_week	수치형	주당 근무시간	40시간에 값이 집중되어 있음
native_country	범주형	출신 국가 관련 범주	결측값 및 소수 범주 존재
income	목표 변수	연 소득 구간	<=50K, >50K 로 구성됨

1.7 소득 그룹 분포

소득 구간	건수	비율
<=50K	24,720	75.92%
>50K	7,841	24.08%

- 두 클래스의 비율이 동일하지 않은 클래스 불균형 데이터임.
- 모든 사람을 <=50K 로 예측하는 단순 모델도 약 75.9%의 Accuracy를 얻을 수 있음.
- Accuracy만으로 모델 성능을 평가할 경우 실제 고소득자를 제대로 분류하지 못하는 문제를 놓칠 수 있음.
- 모델 비교 시 Accuracy와 함께 F1-score, ROC-AUC, PR-AUC를 확인함.
- 학습·평가 데이터 분할 시 stratify=target 을 적용하여 두 데이터의 클래스 비율을 유지함.

2. 데이터 준비 및 EDA

2.1 로딩 및 비교 (Pandas vs Polars)

- Pandas / Polars 둘 다 32,561행 × 15열로 동일하게 로딩되었고, 데이터 타입도 일치함.

항목	Pandas	Polars	비교
행 수	32,561	32,561	일치
열 수	15	15	일치
수치형 컬럼	6	6	일치
dtype	기준	불일치 0개	일치
로딩 시간 (7회 중앙값)	0.0196초	0.0059초	Polars 3.3배 빠름

- 트러블슈팅
 - 원본 CSV가 ", " 형태(콤마 뒤 공백)라, Polars가 공백이 안 지워진 상태로 숫자 컬럼을 파싱하면서 전 컬럼을 문자열로 잘못 인식하는 문제가 있었음.
 - → 전체를 문자열로 읽은 뒤 공백 제거(str.strip_chars).

- → 수치형 컬럼만 다시 int로 캐스팅하는 방식으로 해결.

2.2 EDA

- 기술통계

변수	count	mean	std	min	25%	50%	75%	max
age	32,264	38.523	13.631	17	28	37	47	90
education_num	32,264	10.066	2.562	1	9	10	12	16
capital_gain	32,264	586.92	2,510.933	0	0	0	0	27,828
capital_loss	32,264	81.753	385.366	0	0	0	0	2,415
hours_per_week	32,264	40.39	12.326	1	40	40	45	99

Adult Census Income 탐색적 데이터 분석




그림 1. 소득 그룹별 나이 분포(좌), 교육 수준 분포(우)

분석 항목	관찰된 내용	해석	유의사항
소득 그룹별 나이 분포	<=50K 그룹은 20~40대 초반에 많이 분포하고, >50K 그룹은 35~55세 구간에 상대적으로 집중됨. 두 그룹의 분포는 상당 부분 겹침.	>50K 그룹이 전반적으로 더 높은 연령대에 분포하는 경향이 확인됨.	나이와 소득 간 관련성은 확인되지만, 인과적 관계는 확인할 수 없음.
교육 수준별 소득 그룹 인원 수	HS-grad, Some-college의 전체 인원이 가장 많고 <=50K가 우세함. Bachelors, Masters 등 높은 교육 수준에서는 >50K의 상대적 비중이 증가함. 10th, 11th에서는 >50K가 매우 적음.	교육 수준이 높아질수록 >50K 그룹의 비중이 증가하는 경향이 관찰됨.	해당 그래프는 비율이 아닌 인원 수 기준이므로, 정확한 비교를 위해 교육 수준별 >50K 비율을 추가로 확인해야 함.

주요 범주형 변수 Count bar plot




그림 2. 주요 범주형 변수별 소득 그룹 인원 수

분석 항목	주요 관찰	해석	유의사항
근로 형태	Private 가 가장 큰 비중을 차지하며, 대부분의 근로 형태에서 <=50K 인원이 더 많음. Self-emp-inc 는 다른 근로 형태보다 >50K 비중이 상대적으로 높게 나타남.	근로 형태에 따라 소득 그룹 구성이 다르게 나타나는 경향이 있음.	그래프가 절대 인원 수 기준이므로 근로 형태별 전체 표본 수 차이의 영향을 받음.
혼인 상태	Married-civ-spouse 와 Never-married 의 표본이 많음. Married-civ-spouse 에서는 >50K 인원이 상대적으로 많고, Never-married 에서는 <=50K 가 크게 우세함.	혼인 상태와 소득 그룹 사이에 관련성이 존재할 가능성이 있음.	나이·직업·근무시간 등 다른 변수의 영향이 함께 포함될 수 있으므로 인과관계로 해석할 수 없음.
인종	White 범주에 데이터가 크게 집중되어 있으며, 다른 범주의 표본 수는 상대적으로 적음. 모든 범주에서 <=50K 인원이 더 많음.	인종별 분포 차이보다 먼저 표본 구성 자체의 불균형이 확인됨.	민감 변수이며, 단순 인원 수만으로 집단 간 소득 차이를 비교하기 어려움.
성별	Male 표본이 Female 보다 많으며, Male 에서 >50K 인원이 상대적으로 많이 나타남.	성별에 따라 소득 그룹 구성에 차이가 관찰됨.	성별별 표본 수가 다르므로 >50K 비율을 함께 확인해야 하며, 민감 변수이므로 신중한 해석이 필요함.

2.3 결측치·중복 처리

- 중복 행: 처리 전 32,561행 → 처리 후 32,537행 (24행 제거)
- 결측치 발생 컬럼 (원본에 " ? "로 표기됨)
 - workclass 1,836개, occupation 1,843개, native-country 583개
 - 각 컬럼의 최빈값(mode) 으로 대체




그림 3. 컬럼별 결측치

- 트러블 슈팅
 - 결측치 처리 무효화 문제.
 - `na_values=" ?"` 와 `skipinitialspace=True` 를 함께 사용하면 결측치 처리가 통째로 무효화.
 - `skipinitialspace` 가 공백을 먼저 지워버리는 바람에 `na_values` 가 매칭이 안 됨(`"?"` 가 NaN이 아니라 그냥 문자열 카테고리로 남아있었음)
 - `na_values="?"` (공백 제거)로 수정해 해결.

2.4 이상치 처리

- 이상치 후보 탐색
 - 대상 변수: `age`, `education_num`, `capital_gain`, `capital_loss`, `hours_per_week` (수치형 5종).
 - 방법: Boxplot 시각화 + IQR 규칙
 - $IQR = Q3 - Q1$
 - 하한 $Q1 - 1.5 \times IQR$, 상한 $Q3 + 1.5 \times IQR$
 - 경계 밖 관측치를 이상치 후보로 집계 (변수별 후보 수·비율 산출)

수치형 변수 Boxplot과 이상치 후보




그림 4. Boxplot을 활용한 이상치 후보 선별

- 이상치 처리
 - `age`, `education_num`, `hours_per_week`
 - 후보는 검출되나 현실적으로 가능한 값 → 제거하지 않음.
 - 특히 주당 근무시간은 후보 비율이 높아 일괄 제거 시 정상 관측치 손실이 큼.
 - `income`

- `<=50K` / `>50K` 범주형이므로 IQR 계산 대상 아님.
- `capital_gain`, `capital_loss`
 - 극단값이 실제로 확인됨. → 제외 대상으로 선정.




그림 5. 자본손익 이상치 처리 결과

2.5 EDA 요약

- 수치형 요약 (정제 후 기준):

변수	평균	범위
age	38.6세	17~90세
hours-per-week	40.4시간	1~99시간
education-num	10.1	1~16
capital-gain / capital-loss	대부분 0, 소수만 큰 값	매우 치우친(skewed) 분포

- 타겟 변수(income) 분포
 - `<=50K` 75.9% / `>50K` 24.1% → 클래스 불균형 존재.
- 범주형 특이사항
 - `workclass` 는 `Private` 이 전체의 약 75%를 차지 → 원핫인코딩 시 한계.

3. 시각화 및 검증

3.1 정적 차트 (Seaborn)

- 상관관계 (수치형 변수 간 Correlation Heatmap)




그림 6. 수치형 변수 Heatmap

- 상관계수

- 분석 대상: `age`, `fnlwgt`, `education-num`, `capital-gain`, `capital-loss`, `hours-per-week` 6개 수치형 변수 전수 상관관계 (대각선 1.00은 자기 자신과의 비교 이므로 해석에서 제외.)
- 전반적으로 변수 간 약한 상관관계를 보이고 있음. (전 구간 $|r| \leq 0.15$).
- `capital-gain` / `capital-loss` 는 0이 많은 치우친 분포라 선형 상관계수 해석에 한계가 있음.
- 상관계수는 인과관계를 의미하지 않음.
- 상위 상관 조합

변수 쌍	R^2	관계
교육수준 ↔ 자본이득	0.15	약한 양의 관계
교육수준 ↔ 주당 근무시간	0.14	약한 양의 관계
나이 ↔ 자본이득	0.12	약한 양의 관계

3.2 인터랙티브 차트 (Plotly)

- 종류: 그룹 비교 (직업별 고소득자 비율)
- 파일: `output/figures/income_hours_box.html`
- 해석: 관리직(`Exec-managerial`)의 고소득 비율이 47.8%로 가장 높고, 전문직(`Prof-specialty`)이 44.0%로 뒤를 이음. 반면 개인 가사 서비스(`Priv-house-serv`)는 0.7%로 가장 낮아 직업군별 고소득 비율에 뚜렷한 차이가 나타남. 막대 색상은 고소득 비율 구간을 나타내며, 마우스를 올리면 직업별 비율과 표본 수를 확인할 수 있음. 다만 이는 직업과 고소득 여부의 연관성을 보여주는 결과이며, 직업이 고소득의 직접적인 원인임을 의미하지는 않음.

[plotly_occupation_income.html](#)

[attachment:fdea2d1b-28fd-4e8c-8f0c-58671e618783:plotly_occupation_income.html](#)




그림 8. 직업별 고소득 비율




그림 7. 직업별 고소득 비율 예시 (1)




그림 8. 직업별 고소득 비율 예시 (2)

3.3 평균 차이 검정

- **사전 검정:** Shapiro-Wilk 검정과 Q-Q plot에서 두 소득 그룹 모두 정규성을 만족하지 않는 것으로 확인됨.
- **검정 선택:** 정규성 가정이 필요 없는 Mann-Whitney U 검정을 우선 적용하고, 표본 수가 충분히 크므로 평균 차이와 효과크기를 확인하기 위한 보조 분석으로 Welch t-test를 실시함.

소득 그룹별 주당 근무시간 정규성 진단




그림 9. 소득 그룹별 주당 근무시간 정규성 진단

4.1.1 Mann-Whitney U 검정 결과

- 50K 중앙값: 40.00시간
- <=50K 중앙값: 40.00시간
- U 통계량: 126,060,235
- p-value: < 1e-300
- 순위 양분 상관계수: 0.3406 (중간 정도)
- 해석: $p < 0.05$ 이므로 두 소득 그룹의 주당 근무시간 분포가 같다는 귀무가설을 기각함.

4.1.2 Welch 독립표본 t-test 결과

- 비교 그룹: income **>50K** (n=7,636) vs **<=50K** (n=24,628)
- 비교 변수: **hours_per_week** (평균 45.37시간 vs 38.85시간)
- 평균 차이: 6.52시간 (95% 신뢰구간: 6.23~6.81시간)
 - t-statistic: 44.0899
 - 자유도: 14,130.8
 - p-value: < 1e-300
- 해석: 두 그룹의 평균 주당 근무시간 차이는 통계적으로 유의함. 고소득 그룹이 평균적으로 주당 6.52시간 더 오래 근무했으며, Mann-Whitney U 검정에서도 두 그룹의 근무시간 분포 차이가 유의하게 나타나 두 검정의 결론이 일치함.

4. ML Pipeline 평가

4.1 데이터 분할과 평가 기준

항목	설정
목표값	연소득 >50K 는 1, <=50K 는 0
데이터 분할	훈련 80% / 평가 20%, 소득 비율을 유지하는 계층적 분할(stratify)
평가 데이터	별도 파일이 아닌 동일한 adult.data 에서 떼어 둔 hold-out 20%. UCI adult.test 는 사용하지 않음
클래스 분포	평가 데이터의 >50K 비율 23.7%. 모두 <=50K 로 예측할 때의 Accuracy 0.7634를 기준선으로 사용
재현성	random_state=42

4.2 입력 변수와 전처리

구분	컬럼	Pipeline 처리
수치형	age , education_num , capital_gain , capital_loss , hours_per_week	중앙값으로 결측 대체 후 StandardScaler
범주형	workclass , education , marital_status , occupation , relationship , race , sex , native_country	최빈값으로 결측 대체 후 OneHotEncoder
제외	fnlwgt	개인 특성이 아닌 표본 가중치이므로 모델 입력에서 제외

- handle_unknown="ignore" 는 평가 데이터에만 등장하는 범주값(예: 희소한 native-country)이 들어와도 에러 없이 0 벡터로 처리하기 위한 설정.
- 결측 대체·스케일링·One-Hot Encoding은 Pipeline 안에서 훈련 데이터에만 학습해 평가 데이터의 정보가 전처리에 섞이지 않도록 함.

4.3 비교 모델 선택 이유

모델	선택 이유	비교에서 확인할 점
Logistic Regression	구조가 단순하고 결과를 설명하기 쉬운 선형 분류 모델이므로 기본 성능을 확인하는 기준 모델로 선택.	변수와 소득 사이의 관계를 선형 결정경계만으로 어느 정도 구분할 수 있는지 확인.
Random Forest	여러 결정트리의 결과를 평균내는 배깅 앙상블로, 수치형·범주형 변수가 섞인 표 형식 데이터의 비선형 관계와 변수 간 상호작용을 학습할 수 있어 선택.	선형 모델이 놓치는 복잡한 패턴을 학습했을 때 성능이 얼마나 개선되는지 확인.
HistGradientBoosting	앞선 트리의 오차를 다음 트리가 순차적으로 보완하고, 연속값을 구간화해 비교적 빠르게 학습하는 부스팅 모델이므로 고성능 후보로 선택.	배깅 방식인 Random Forest보다 오분류를 정교하게 보완해 ROC-AUC와 PR-AUC를 높이는지 확인.

- 세 모델은 선형 모델, 배깅 앙상블, 부스팅 앙상블을 각각 대표.
- 서로 다른 학습 방식을 같은 데이터 분할과 전처리 조건에서 비교해 모델 복잡도를 높였을 때 실제 평가 성능이 개선되는지 확인하려는 구성.

4.4 평가결과

- 최종 파이프라인 성능
 - 세 모델에 동일한 데이터 분할과 전처리를 적용했으며, ROC-AUC가 가장 높은 HistGradientBoosting 을 최종 Pipeline으로 저장.
 - 양성 클래스가 소수인 불균형 데이터에서는 ROC-AUC가 실제보다 낙관적으로 보일 수 있어, 양성 클래스 기준의 PR-AUC(Average Precision)를 함께 보고.
 - 또한 Random Forest에만 class_weight="balanced_subsample" 을 적용했으므로, 기본 임계값 0.5에 의존하는 Accuracy·F1은 세 모델을 완전히 동일한 조건에서 비교한 값이 아님.
 - 따라서 임계값과 무관한 ROC-AUC·PR-AUC를 중심으로 비교하는 것이 공정.
 - 2번 섹션에서 확인한 클래스 불균형(75.9% vs 24.1%) 때문에, 전체 Accuracy 0.86에 비해 소수 클래스(>50K)의 recall이 0.62로 낮음.
 - 즉 실제 고소득자 10명 중 약 4명은 놓치는 모델

모델	Accuracy	F1	ROC-AUC	PR-AUC	훈련 시간
Logistic Regression	0.8446	0.6362	0.8988	0.7451	0.151초
Random Forest	0.8097	0.6819	0.9096	0.7667	0.665초
HistGradientBoosting	0.8695	0.7016	0.9234	0.8124	1.502초




그림 10. 모델별 ROC Curve




그림 11. 분류 모델 평가 지표

• 클래스별 성능

클래스	precision	recall	f1-score	support
<=50K	0.89	0.93	0.91	4,940
>50K	0.74	0.62	0.68	1,568

4.5 모델 저장 및 재현성 검증

```

===== test session starts =====
platform darwin -- Python 3.11.15, pytest-9.1.1, pluggy-1.6.0 -- /Users/hayeon/workspace/data-project/teamproject/.venv/bin/python3.11
cachedir: .pytest_cache
rootdir: /Users/hayeon/workspace/data-project/teamproject
plugins: anyio-4.14.2
collecting ... collected 9 items

tests/test_clean.py::test_clean_nulls_mode fills with most frequent value PASSED ( 11%)
tests/test_clean.py::test_clean_nulls_median fills numeric column PASSED ( 22%)
tests/test_clean.py::test_clean_nulls_drop removes rows with null PASSED ( 33%)
tests/test_clean.py::test_clean_nulls_invalid_strategy raises PASSED ( 44%)
tests/test_clean.py::test_clean_nulls_does_not_mutate original PASSED ( 55%)
tests/test_clean.py::test_drop_duplicate_rows removes exact duplicates PASSED ( 66%)
tests/test_clean.py::test_load_pandas matches expected shape PASSED ( 77%)
tests/test_clean.py::test_load_pandas and polars agree on row count PASSED ( 88%)
tests/test_clean.py::test_load_and_clean has no nulls and no duplicates PASSED (100%)

===== 9 passed in 0.28s =====

```

그림 12. pytest 실행결과 화면

```

python src/run_pipeline.py

중복 제거 전: 32,561행 -> 제거 후: 32,537행 (제거됨: 24행)
(t-test) '>50K' vs '<=50K' on 'hours-per-week'
>50K 평균: 45.47 (n=7,839)
<=50K 평균: 38.84 (n=24,698)
t-statistic: 45.0950
p-value: 0.0000
-> 유의수준 0.05에서 '>50K' 그룹과 '<=50K' 그룹의 'hours-per-week' 평균 차이는 통계적으로 유의하다.
(Pipeline) train=26,029 / test=6,508
(Pipeline) accuracy=0.8569, f1=0.6762
precision recall f1-score support

<=50K      0.89      0.93      0.91      4940
>50K       0.74      0.62      0.68      1568

accuracy            0.86      6508
macro avg          0.81      0.78      0.79      6508
weighted avg       0.85      0.86      0.85      6508

(Pipeline) 모델 저장 완료: /Users/hayeon/workspace/data-project/teamproject/output/model.pkl
(Pipeline) 제로팅 후 accuracy=0.8569 (원본과 일치: True)

전체 파이프라인 완료. 리포트: /Users/hayeon/workspace/data-project/teamproject/output/report.md

```

그림 13. 파이프라인 자동화 실행결과 화면

5. 분석 결과 및 결론

• 주요 인사이트

- 교육수준과 소득, 유의미하게 연관됨. 카이제곱 검정 $p < 0.05$ 로 독립 기각, Cramér's V 0.3617(중간 효과)
- 소득 그룹 간 근무시간 차이 유의함. Mann-Whitney U(순위 양분 상관 0.3406), Welch t-test(평균차 6.52시간, Cohen's d 0.5428) 모두 중간 효과로 일관.
- 수치형 변수 간 선형 상관은 전반적으로 약함($|r| \leq 0.15$). fmlwgt는 표본 가중치라 다른 변수와 무관 → 모델 입력 제외 타당.
- 최종 모델은 HistGradientBoosting. ROC-AUC 0.9234, PR-AUC 0.8124로 3개 모델 중 최고.

- 클래스 불균형 존재(<=50K 75.9% / >50K 24.1%). 기준선 Accuracy 0.7634 자체가 높아 Accuracy만으로 평가 부족.

• 한계점

- 이상치 제외 경계를 train/test 분할 전 전체 데이터로 계산 → 데이터 누수 가능성
- 단일 hold-out 분할만 사용, 교차검증 미수행.
- Random Forest에만 class_weight 적용 → Accuracy-F1은 3개 모델 완전 동일 조건 비교 아님.
- 성별·인종 등 민감 변수 포함됐지만 그룹별 공정성 검토 안 함.
- 극단 자본손익 273행(0.84%) 삭제 → 지표가 원본 분포보다 낙관적일 수 있음.
- f1wgt 미활용 → 모집단 수준 일반화엔 한계.

• 향후 개선 방향

- 이상치 경계는 train 데이터에서만 계산, 삭제 대신 winsorizing/로그 변환 검토.
- 교차검증 + 하이퍼파라미터 탐색으로 지표 신뢰도 확보, 불균형 처리는 3개 모델에 동일 적용.
- Precision-Recall + 그룹별(성별·인종) 성능 비교로 공정성 검토 추가.
- f1wgt로 모집단 수준 가중 추정 분석 별도 수행.
- 모델 결과를 개인 능력·가치 판단 근거로 쓰지 않도록 활용 가이드라인 명시.

6. 팀원별 인사이트 및 의견

이름	역할
김지호	시각화, 파이프라인 자동화
김상훈	데이터 준비 및 기초 EDA
김하연	EDA, 데이터 전처리(결측치 및 이상치 처리)
박도현	ML 파이프라인 및 모델 평가
이슬	시각화, 통계적 검증

• 김지호 — 시각화, 파이프라인 자동화

- **인사이트:** Plotly를 활용한 직업군별 고소득 비율 분석 결과, 관리직(Exec-managerial, 47.8%)과 전문직(Prof-specialty, 44.0%)의 고소득 비율이 가장 높았으며, 개인 가사 서비스(Priv-house-serv, 0.7%)는 가장 낮아 직업군에 따른 소득 격차가 뚜렷하게 나타났다.
- **의견:** 인터랙티브 시각화를 통해 범주형 데이터의 분포를 보다 직관적으로 확인할 수 있었으며, 분석 결과를 자동으로 반영하는 파이프라인을 구축해 재현성과 유지보수 효율을 높일 수 있었다.

• 김상훈 — 데이터 준비 및 기초 EDA

- **인사이트:** 동일한 데이터셋(32,561행 × 15열)을 비교한 결과, Polars의 로딩 시간은 0.0059초로 Pandas의 0.0196초보다 약 3.3배 빨랐음. 또한 CSV 값의 앞뒤 공백으로 인해 Polars가 일부 수치형 데이터를 문자열로 인식하는 문제를 확인했으며, `strip_chars()` 적용 후 형 변환을 수행하여 해결함.
- **의견:** Pandas와 Polars의 처리 결과를 함께 검증한 방식은 데이터 정확성과 성능을 확인하는 데 효과적임. 다만 공백 제거와 자료형 변환 로직을 공통 전처리 함수로 분리하면 코드 중복을 줄이고 유지보수성을 높일 수 있음.

• 김하연 — EDA, 데이터 전처리

- **인사이트:** 전체 32,561건 중 24건의 중복 데이터를 제거하고, `workclass`, `occupation`, `native_country` 변수의 '?' 결측값을 최빈값으로 대체하였다. 또한 `age`, `hours_per_week` 등의 이상치는 실제 데이터 특성을 반영한다고 판단하여 유지하고, `capital_gain`과 `capital_loss`는 변수 특성을 고려해 별도로 검토하였다.
- **의견:** 전처리 과정에서는 단순한 규칙 적용보다 데이터의 특성을 고려한 판단이 중요하다는 점을 확인하였다. 특히 결측치 처리 옵션과 이상치 판별 기준이 분석 결과에 큰 영향을 줄 수 있어, 데이터의 의미를 반영한 전처리 기준을 마련하는 것이 중요하다고 생각하였다.

• 박도현 — ML 파이프라인 및 모델 평가

- **인사이트:** Logistic Regression, Random Forest, HistGradientBoosting을 비교한 결과 HistGradientBoosting이 Accuracy 0.8695, ROC-AUC 0.9234, PR-AUC 0.8124로 가장 우수한 성능을 보였다. 또한 클래스 불균형 환경에서는 Accuracy뿐 아니라 F1-score와 PR-AUC를 함께 고려해야 하며, 고소득 그룹 Recall이 상대적으로 낮아 추가 개선이 필요함을 확인하였다.
- **의견:** Scikit-learn Pipeline을 활용해 전처리와 학습 과정을 통합함으로써 데이터 누수를 방지하고 재현성을 확보하였다. 또한 joblib 기반 모델 저장 및 재로드를 통해 동일한 성능이 재현됨을 확인했으며, 향후 불균형 데이터 처리와 임계값 조정을 추가적으로 적용하면 성능을 더욱 개선할 수 있을 것으로 판단하였다.

• 이슬 — 시각화, 통계적 검증

- **인사이트:** Shapiro-Wilk 검정을 통해 두 소득 그룹 모두 정규성을 만족하지 않음을 확인하여 Mann-Whitney U 검정을 적용하였다. 검정 결과 주당 근무시간 차이는 통계적으로 유의미했으며, Welch t-test에서도 동일한 결론을 확인하였다. 또한 교육수준과 소득 간에는 카이제곱 검정과 Cramér's V를 통해 중간 수준 이상의 연관성이 있음을 확인하였다.
- **의견:** 분석 과정에서 단순히 유의확률(p-value)만 확인하는 것이 아니라 효과 크기까지 함께 해석하는 것이 중요하다는 점을 다시 확인하였다. 적절한 통계 검정을 선택하고 결과를 다각도로 검증함으로써 분석의 신뢰성을 높일 수 있었다.